


第 6 章 数据链路层与局域网


中国科学技术大学
自动化系 郑烜
改编自Jim kurose, Keith Ross



Computer Networking: A Top-Down Approach
8th edition
Jim Kurose, Keith Ross
Pearson, 2020

链路层：导论

- 网络层：解决了一个网络如何到达另一个网络的问题，通过路由和转发
- 路由：路由算法给路由器指定了达目标子网的下一跳，与某接口同在一个IP子网的邻居节点
- 转发：对任何接口到来的分组，做FIB表的匹配，从一个子网接口转到（搬到）另外一个子网接口，在两个子网间做分组转发
- 依赖于：执行这个向下一跳的发送，即：在一个IP子网内，一个IP可以顺利将分组发给同属于一个子网的另外一个IP地址（下一跳）
- 链路层提供同一个IP子网内2个IP地址间分组传输的服务
 - 从IP层的角度来看是一跳(hop)，相邻
 - 从链路层的角度来看可能是多个物理跳，通过多个交换机，或者AP、交换机



Link Layer: 6-2

数据链路层与局域网：目标


- 理解链路层服务背后的原理：
 - 检错、纠错
 - 广播型信道的共享：多路访问
 - 链路层编址
 - 局域网：以太网、VLAN
- 各种链路层技术的实例和实现
- 数据中心网络



Link Layer: 6-3

链路层和局域网：提纲

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络



- Web请求的历程


Link Layer: 6-4

链路层：简介

术语：

- 节点：主机、路由器、交换机
- 链路：在同一个网络内部将邻近的节点连在一起的通信信道
 - 有线，无线，局域网
- 第2层的协议数据单位PDU：帧
 - 用于封装IP数据报

链路层 负责将IP数据报通过链路从一个节点传送到物理上相邻的（同在一个IP子网的）另外一个节点



Link Layer: 6-5

链路层：上下文

- 同一个IP数据报在不同跳上的链路可能使用不同链路层协议传输
 - 例如：第一段链路WiFi，下一段链路为以太网
- 每种链路层协议提供的服务是不同的
 - 例如：在有些链路层提供可靠数据传输，有些不提供rdt


交通的类比：

- 普林斯顿到洛桑的旅行
 - 轿车：普林斯顿到JFK
 - 飞机：JFK到日内瓦
 - 火车：日内瓦到洛桑
- 旅行者 = IP数据报
- 交通代理 = 路由算法
- 每个交通段（车辆）= 通信链路
- 交通模式 = 链路层协议

Link Layer: 6-6

链路层：服务


- 成帧，链路接入：
 - 封装IP数据报到帧中，加上帧头和帧尾
 - 如果共享型介质，发送之前需要信道接入
 - 在帧的头部加入“MAC”地址标识帧的源以及目标（和IP地址不在一个层次）
- 在相邻节点之间进行可靠数据传输
 - 前面已经学过如何进行可靠数据传输
 - rdt在低出错率链路上（如以太网）很少使用
 - Rdt在高出错率的无线链路（WLAN，4G/5G）上，经常采用
 - Q: 为什么链路层可靠性和端到端可靠性都要有？



Link Layer: 6-7

链路层：服务（续）


- 流量控制：
 - 在相邻的发送和接收节点控制帧的间隔，从而控制发送速率
- 差错检验：
 - 错误通常由信号间的干扰和噪声引起
 - 接收方检测差错，发送方重传或者丢弃错误的帧
- 差错纠正：
 - 无需重传，接收方就可以标识和纠正比特错误
- 半双工和全双工通信：
 - 在半双工情况下，链路两端的节点都可以发送，但是不能同时进行



Link Layer: 6-8


在哪里实现链路层?

- 在每台主机、路由器的网卡上，或者交换机的网口上
- 链路层（和相应的物理层）实现于网络接口卡（*NIC: network interface card*）或者芯片上
 - 以太网网卡，WiFi网卡或者设备主板上的交换芯片
 - 实现了链路层和和相应物理层功能
- 网卡连接到了（或者路由器）的系统总线，通过驱动和设备的OS相连
- 硬件、软件和固件的组合



Link Layer: 6-9

网络接口（路由器接口、主机接口）间的通信



发送方:

- 封装IP数据报到帧中
- 增加差错检测位，执行可靠数据传输和流量控制机制等功能

接收方:

- 检查帧有无出错，执行可靠数据传输和流量控制等功能
- 解封IP装数数据报，在接收节点将之交给上层（如路由器的网络层实体）

Link Layer: 6-10

链路层，LAN：提纲

- 引论
- 检错，纠错**
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络




Web请求的历程

Link Layer: 6-11

差错检测

EDC: 差错检测和纠正编码位 (即: 冗余位)

D: 被差错检测编码保护的数据, 可能包括PDU头部字段的内容



差错检测不是100%可靠的!


- 协议可能遗漏一些错误，但是非常少（残存错误）
- EDC越强大、EDC越长：检测和纠正的效果越好

Link Layer: 6-12

奇偶校验

单比特校验:


- 检测单个位的错误



偶校验: 设置校验位使得1的位数为偶数

2维比特校验:

- 可以检测和纠正单个位的错误



no errors: $\begin{array}{cccc|c} 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \end{array}$

detected and correctable single-bit error: $\begin{array}{cccc|c} 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 \end{array}$

parity error

* Check out the online interactive exercises for more examples: http://gaia.cs.umass.edu/kurose_ross/interactive/

Link Layer: 6-13

互联网校验和 (复习)

目标: 在传输的段中检查错误 (例如: 反转的位)

发送方:

- 将UDP数据报的内容当成16比特的整数序列 (包括UDP头部和IP地址)
- 校验和: 校验范围的内容和 (和的反码)
- 校验和的值放入UDP校验和字段


接收方:

- 计算接收段的校验和
- 检查计算出的校验和是否等于校验和字段的值:
 - 不相等---出错了
 - 相等---没有错误被检查出来, 但是可能存在错误?
 - 残存错误

Transport Layer: 3-14

循环冗余校验码 (CRC: Cyclic Redundancy Check)

- 更为强大的差错检测码
- D (数据位): 给定的, 将之视为二进制位的序列
- G (生成器): 发送方接收方约定的一个r+1位序列 (r阶, r+1位)



目标: 计算出r位CRC位R, 让<D,R>能够被G (模2运算) 整除

- 接收器知道G, 将<D, R>除以G, 如果余数非零: 检测到错误!
- 可以检测到小于r+1位的所有突发错误
- 在实际中广泛使用 (以太网、802.11 WiFi)

Link Layer: 6-15

Cyclic Redundancy Check (CRC): 例子

我们希望:

$$D \cdot 2^r \text{ XOR } R = nG$$


或者等价的:

$$D \cdot 2^r = nG \text{ XOR } R$$

或者等价的: :

如果希望 $D \cdot 2^r$ 可以整除G, 则余数R应该满足:

$$R = \text{remainder} \left[\frac{D \cdot 2^r}{G} \right]$$



* Check out the online interactive exercises for more examples: http://gaia.cs.umass.edu/kurose_ross/interactive/

Link Layer: 6-15

链路层，LAN：提纲

- 引论
- 检错，纠错
- **多路访问协议**
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络



- Web请求的历程

Link Layer: 6-17

多路访问链路、协议

2种类型的“链路”将相邻2个节点连接起来：

- 点到点
 - 连接远端2台路由器的点到点链路
 - 以太网交换机和主机的点到点链路
 - 用于拨号接入的PPP
- **广播式 (共享线缆或者媒体)**
 - 老式总线型以太网（同轴电缆连接各主机）
 - 有线（cable）接入网络中的上行HFC
 - 802.11 WLAN，4G/5G，卫星网络



Link Layer: 6-18

多路访问协议（MAP）

- 单个的共享型广播信道
- 如果2个或者多个节点的同时发送：干扰
 - **碰撞**：如果接收节点同时接收到了2个或者多个信号，将无法分清谁发送的到底是什么

多路访问协议

- 决定节点如何共享信道的分布式算法，即确定节点什么时间可以发送
- 关于信道共享的通信协调必须借助于信道本身！
 - 没有用于协调的带外信道

Link Layer: 6-19

理想的多路访问协议

给定：速率为Rbps的多路访问信道(MAC)

理想特性：

1. 当一个节点发送时，它可以按照信道设计的速率R进行全速传输
2. 当M个节点发送时，每个节点按照R/M平均速率发送
3. 完全分布式：
 - 没有用于协调传输的特殊节点
 - 无需在时钟上和时隙上进行同步
4. 简单

Link Layer: 6-20

MAC协议：分类

2025中科大网络

3大类型：

- **信道划分**
 - 将信道划分为更小的“分片”（时隙、频段、编码和光的波段）
 - 将“分片”分配给节点用于其独享
- **随机访问**
 - 信道不再划分为分片，允许碰撞
 - 要有从碰撞中恢复的机制
- **轮次（依次轮流）**
 - 节点轮流使用，拥有很多数据传输的节点会得到更多的轮转使用时间


Link Layer: 6-21

信道划分MAC协议：TDMA

2025中科大网络

TDMA: time division multiple access 时分多路复用

- “轮流”访问信道
- 每个站点在每一轮中获得固定长度的时隙（长度=包发送时间）
- 没有使用的时隙会空闲，此时信道的资源会被浪费
- 例子：6个站点的LAN，1、3、4时隙有数据发送，2、5、6时隙空闲




Link Layer: 6-22

信道划分MAC协议: FDMA

2025中科大网络

FDMA: frequency division multiple access 频分多路复用

- 信道频谱被分为频带
- 每个站点被分配给一个固定的频带，在该频带上传输
- 某个频带上若未被使用，该频带会被浪费
- 例子：6个站点的LAN，1、3、4有包发送，频带2、5、6空闲



Link Layer: 6-23

随机访问协议

2025中科大网络

- 当一个节点有数据包要发送时：
 - 按照全信道速率R发送
 - 节点间没有预先的协调
- 2个或多个正在传输的节点会发生“碰撞”
- **随机访问协议要规范：**
 - 如何检测碰撞
 - 如何从碰撞中恢复（例如：通过延后的重传）
- 随机访问MAC协议的例子：
 - ALOHA, slotted ALOHA
 - CSMA, CSMA/CD, CSMA/CA

Link Layer: 6-24

时隙 ALOHA

假设:

- 所有的帧大小一样
- 时间被分成相等大小的时隙 (传输一个帧所用的时间)
- 节点仅仅在时隙的开始才能进行传输
- 所有节点需要在时间上同步
- 如果2个或者多个节点在一个时隙上传输, 所有节点都会检测出碰撞


运行:

- 当节点获得了一个新帧, 在下一个时隙进行传输
 - 如果没有碰撞: 该帧发送成功, 节点可在下一个时隙发送新帧
 - 如果发生碰撞: 节点将会在下一个时隙以概率 p 发送, 直到成功

随机化 - 为什么?

Link Layer: 6-25

时隙 ALOHA



优点:

- 单个活动节点可以以信道全速率进行连续发送
- 高度分布式: 仅需要节点在时间上同步
- 简单

缺点:

- 有碰撞, 存在浪费时隙的情况
- 即使有帧要发送, 也有空闲的时隙
- 如果有碰撞, 节点可以在小于一个帧传输时间内检测到碰撞, 但还必须要发完该帧
- 节点需要时钟上的进行同步

Link Layer: 6-26

时隙 ALOHA: 效率


效率: 长期来看, 成功时隙所占的比例 (假设有很多节点, 每个节点都有很多帧要发送)

- 假设: N 个具有很多帧要发送的节点, 每个节点在时隙中传输的概率为 p
 - 节点在一个时隙中成功发送的概率 = $p(1-p)^{N-1}$
 - 任何一个节点成功发送的概率 = 信道成功传输帧的概率 = $Np(1-p)^{N-1}$
 - 最大利用率: 找到能够让 $Np(1-p)^{N-1}$ 最大化的 p
 - 对于很多节点而言, 当 N 趋于无穷时, 求 $Np(1-p)^{N-1}$ 的极限, 得到:
 - 最大效率 = $1/e = .37$
- 最好情况: 信道有37%的时间被用于有效的帧传输!

Link Layer: 6-27

纯 ALOHA

- 不分隙 Aloha: 简单, 无需时间上同步
 - 一旦帧到达: 立即传输
- 由于没有同步, 碰撞的概率增加:
 - 在 t_0 时开始传输的帧 (黄色) 会和其他的在 $[t_0-1, t_0+1]$ 开始传输的帧碰撞



- 纯Aloha的最大效率: 18.5% !

Link Layer: 6-28

2025中科大网络 CSMA (carrier sense multiple access)

简单 CSMA: 为了进一步提供信道利用率, 在传输之前侦听:


- 如信道空闲: 传送整个帧
- 如信道忙碌: 推迟发送, 直到信道空闲
- 人类的类比: 先听后说, 不要打断别人正在进行的说话!

Link Layer: 6-29

CSMA: 碰撞

- 即使有载波侦听, 仍可能发生碰撞
 - 节点间的传播延迟决定了A节点可能听不到另外一个节点B刚开始的传输
- 碰撞时: 如果坚持将一个帧发送给完毕, 该帧的整个传输时间会被浪费掉
 - 距离和传播延迟越大, 碰撞概率越大,
 - 碰撞时浪费的信道情况越严重

原因: 节点依据本地的信道使用情况来判断全局信道的使用情况




Link Layer: 6-30

CSMA/CD:

CSMA/CD: CSMA with *collision detection*

- 碰撞将会在一小段时间内就被检测到
- 碰撞的传输会被立即中止, 可以进一步降低对信道的浪费
- 在有线网络中碰撞很容易被检测到, 但是在无线网络中很难检测到碰撞 (WLAN 采用CSMA/CA, 而不是CSMA/CD)
- 人类类比: 有礼貌的说话者, 我在说的时侯如果别人说话, 我就立即停止
 - 先听后说CS, 边听边说CD



Link Layer: 6-31

Ethernet CSMA/CD 算法

1. NIC从网络层接收到数据报 (和目标MAC地址), 创建帧
2. NIC 检测信道:
 - 如果空闲: 立即开始帧的传输
 - 如果忙碌: 侦听信道直到空闲, 然后开始传输
3. 传输时CD, 如 NIC在传输一整个帧时都没发生碰撞, NIC成功完成了该帧的传输! (无需等确认, 以太网在链路层不提供可靠传输)
4. 如果 NIC 在发送时检测到其他的传输: 放弃, 发送jam干扰信号, 强化冲突
5. 在放弃之后, NIC 进入 二进制 (指数) 退避:
 - 在第m次碰撞后, NIC在 $\{0, 1, 2, \dots, 2^m - 1\}$ 中随机选择一个值K, NIC等待K*512位时后, 返回第2步尝试重传
 - 更多的碰撞: 退避时间间隔更长 (在发生碰撞的可能性和节点平均发送时间之间取得权衡, 以适应当前信道负载的变化)

Link Layer: 6-32

以太网CSMA/CD算法（续）

二进制指数退避：

- 目标：适配器试图适应当前负载，在一个适应性的、变化的碰撞窗口中随机选择时间点尝试重发
 - 高负载：重传窗口时间大，冲突可能性减少，但等待时间长
 - 低负载：使得各站点等待时间少，但碰撞窗口小冲突可能性增大

- 首次碰撞：在{0, 1}选择K；延迟K*512位时尝试重发
- 第2次碰撞：在{0, 1, 2, 3}选择K，延迟K*512位时尝试重发
-
- 第10次碰撞：在{0, 1, 2, 3,, 1023}选择K, 延迟K*512位时尝试重发
- 超过10次连续碰撞，报错

Link Layer: 6-33

CSMA/CD 效率


- T_{prop} = LAN中2个站点最大传输延迟
- t_{trans} = 最大尺寸帧的传输时间

$$efficiency = \frac{1}{1 + 5t_{prop}/t_{trans}}$$

- 效率=1的2种可能：
 - 当 t_{prop} 趋近于0时：一旦一个帧发送，CS机制立即让所有节点检测到，信道不会发送冲突
 - 当 t_{trans} 趋近于无限大时：一个节点一旦占据信道，会一直发送
- 比ALOHA的性能要好：而且简单、便宜、分布化！

Link Layer: 6-34

Manchester 编码



- 在 10BaseT中使用
- 每一个bit的位时中间有一个信号跳变
- 允许在接收方和发送方节点之间进行时钟同步
 - 节点间不需要集中的和全局的时钟
- 10Mbps，信号占用20M带宽，效率50%
- 这已经是物理层的内容了！

Link Layer: 6-35

100BaseT中的4b5b编码

- | | |
|-------------|-------------|
| 0000->11110 | 1000->10010 |
| 0001->01001 | 1001->10011 |
| 0010->10100 | 1010->10110 |
| 0011->10101 | 1011->10111 |
| 0100->01010 | 1100->11010 |
| 0101->01011 | 1101->11011 |
| 0110->01110 | 1110->11100 |
| 0111->01111 | 1111->11101 |

Link Layer: 6-36

千兆以太网

- 采用标准的以太帧格式
- 允许点对点链路和共享广播信道
- 交换模式：全双工千兆可用于点对点链路
 - 站点使用专用信道，不会冲突，效率高
 - 除非发往同一个目标站点，多打一情况下在交换机中会增加延迟
- 在共享模式中，继续使用 CSMA/CD MAC 技术，节点间需要较短距离以提高利用率
- 物理编码：8b10b 编码
- 800 Gbps now !

Link Layer: 6-37

“轮次” MAC 协议

信道划分 MAC 协议：

- 低负载时：低效，信道访问的延迟，即使只有一个站点活跃它也只能获得 $1/N$ 带宽！
- 高负载时：高效、公平性地共享信道

随机访问 MAC 协议

- 低负载时：高效，单个忙碌的节点可以充分利用信道！
- 高负载时：反复碰撞，信道的浪费很严重

“轮次” 协议


- 具备以上二者的优点！

Link Layer: 6-38

“轮次” MAC 协议

轮询：

- 主节点依次“邀请”其它节点进行传输
- 经常与“哑”设备一起使用
- 关注点：
 - 轮询代价
 - 延迟（节点传输完毕必须要等待主节点轮询一周之后才可以传输）
 - 单点故障点（主节点）




Link Layer: 6-39

“轮次” MAC 协议

令牌传递：


- 控制令牌依次从一个节点传到下一个节点
- 节点截获令牌进行数据的传输
 - 将令牌改变成数据帧
 - 传完数据帧之后，在信道上恢复令牌交给下游节点
- 关注点：
 - 令牌代价
 - 延迟
 - 单点故障（令牌）



Link Layer: 6-40

有线接入网络: FDM, TDM 和随机访问的综合运用!

2025中科大网络




- ❖ 从头端到各终端的下行(广播)信道通过FDM分为多个40Mbps信道
 - 互联网信道: 只有1个CMTS传输下行数据(携带有接收站点地址), 专享
 - 广播的数字电视、分配给终端的使用上行信道的控制信息等
- ❖ 多个30 Mbps上行的信道, FDM
 - 多路访问: 所有终端用户使用; 接着TDM分成微时隙
 - 部分时隙: 分配用于各终端传输数据; 部分时隙: 用于竞争式进行信道预约

Link Layer: 6-41

有线接入网络:

2025中科大网络




DOCSIS: data over cable service interface specification

- ❖ 采用FDM进行信道的划分: 若干上行、下行信道
- ❖ 下行信道:
 - ❖ 时隙分配结果: 在下行MAP帧中, CMTS告诉各终端微时隙分配方案, 分配给各终端的上行微时隙
 - ❖ 互联网下行数据: CMTS头端传输下行数据(给各用户)

Link Layer: 6-42

有线接入网络:

2025中科大网络



DOCSIS: TDM上行信道

- ❖ 采用TDM的方式将上行信道分成若干微时隙: MAP规定
- ❖ 站点采用分配给它的数据微时隙上行数据传输: CMTS分配的
- 在特殊的上行微时隙中, 各站点请求上行微时隙: 竞争
 - 各站点对于该时隙的使用是随机访问的
 - 一旦碰撞(请求不成功, 结果是: 在下行的MAP中没有为它分配, 则二进制退避)随机选择时隙请求上行数据微时隙

Link Layer: 6-43

MAC协议总结

2025中科大网络

- 信道划分, 通过划分时间, 划分频率或者编码
 - TDMA, FDMA, CDMA
- 随机访问(动态),
 - ALOHA, S-ALOHA, CSMA, CSMA/CD
 - 载波侦听: 在有些网络中容易(有线), 而在有些很难(无线)
 - CSMA/CD 在以太网中被使用
 - CSMA/CA 在 802.11 WLAN中被使用
- 轮次
 - 通过中心节点的轮询, 分布式的令牌传递
 - 蓝牙, FDDI, 令牌环

Link Layer: 6-44

链路层，LAN：提纲

2025中科大网络

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络



- Web请求的历程

Link Layer: 6-45

MAC 地址

2025中科大网络

- 32-bit IP 地址:
 - 接口的网络层地址，被用于三层（网络层）的转发
 - IP地址是分层的，便于进行全互联网的路由计算
 - e.g.: 128.119.40.136
- MAC (or LAN or physical or Ethernet) 地址:
 - 功能:
 - 在一个IP子网范围内区分一个网卡（主机、路由器）和其他一些网卡
 - MAC地址平面的
 - 在一个LAN，从一个LAN接口将帧传递到LAN的另外一个接口
 - 48位MAC地址（对于大多数LANs）被烧入到NIC ROM中，但是有时候支持软件设置
 - e.g.: 1A-2F-BB-76-09-AD

十六进制表示法
(每位“数字”代表4 bit)


Link Layer: 6-46

MAC 地址

2025中科大网络

每个在LAN中的接口，都拥有2各层面的地址

- 网络层：拥有一个逻辑上唯一的32位IP地址
- 链路层：拥有唯一的48位MAC地址



Link Layer: 6-47

网络地址和mac地址分离

2025中科大网络

历史原因：先有各种物理网络（有各自MAC地址），再有IP网络互联（需要定义统一的IP地址）

分离的好处

- a) 更换坏的网卡，MAC地址变化而IP地址不变，不影响使用
- b) 物理网络之上可以支持IP之外的其他网络层协议，如IPX，Appletalk等

捆绑的问题

- a) IP地址和MAC地址捆绑，意味着只能选择IP协议
- b) 每次上电都要写入IP地址
- c) 另外一个选择：每到来一个帧都要上传到IP层，IP协议实体被中断一次，由它判断是不是需要接收，代价大

Link Layer: 6-48

MAC 地址

2025中科大网络


- MAC地址分配被IEEE管理
- 厂商购买MAC地址段来确保地址的全球唯一性
- 类比：
 - MAC地址：就像社会安全号（身份证号）
 - IP地址：类似于邮政地址
- MAC平面性地址：可移动性
 - 可以将网卡从一个LAN移动到另外一个LAN，不用改变MAC地址
 - 而IP地址不可移动：取决于节点所连接的IP子网

Link Layer: 6-49

ARP: address resolution protocol

2025中科大网络

Question: 知道接口的IP地址，如何确定接口的MAC地址？



ARP 表: 每个在LAN上的IP节点（主机，路由器）都有该表格

- LAN节点的一些IP/MAC 地址映射：
 - < IP address; MAC address; TTL>
- TTL (Time To Live): 地址映射将会在该时间之后老化（典型20分钟）

Link Layer: 6-50

ARP协议的运行

2025中科大网络


例子: A 需要发送IP数据报给B

- B的 MAC地址不在A的 ARP表中, 所以A采用ARP协议想获知B的MAC地址

① A 广播 ARP 查询, 包含B的IP地址

- 目标MAC地址 = **FF-FF-FF-FF-FF-FF**
- 所有的LAN节点都会收到该ARP查询

ARP table in A		
IP addr	MAC addr	TTL



Link Layer: 6-51


ARP协议的运行

2025中科大网络

例子: A 需要发送数据报给B

- B的 MAC地址不在A的 ARP表中, 所以A采用ARP协议获知B的MAC地址

ARP table in A		
IP addr	MAC addr	TTL




Link Layer: 6-52

ARP协议的运行

例子: A 需要发送数据报给B

- B的 MAC地址不在A的 ARP表中, 所以A采用ARP协议获知B的MAC地址




Link Layer: 6-53

路由到其他子网: 寻址

演练: 通过R将数据报从A发送到B


- 聚焦于寻址 – 在 IP (数据报)层 和 MAC 层 (帧)
- 假设:
 - A 知道B的IP地址
 - A 知道送达分组给B的IP地址, 第一跳路由器R的IP地址 (如何? DHCP)
 - A 知道R的MAC地址 (如何? ARP)



Link Layer: 6-54

路由到其他子网: 寻址


- 创建IP数据报: 源IP地址A, 目标IP地址为B
- 创建包含A到B IP数据报的链路层帧
 - R的 MAC 地址当作是帧的目标地址 (R的MAC地址通过ARP获得)



Link Layer: 6-55

路由到其他子网: 寻址

- 帧从A发送到R
- 帧被R接收, 数据报被解封装, 向上交给IP协议实体




Link Layer: 6-56

2025中科大网络

路由到其他子网：寻址

- R决定数据报的传出接口，将源IP地址为A，目标IP地址为B的数据报交链路层
- R创建链路层的帧包含A-B IP数据报，帧的目标地址：B的MAC地址（通过ARP获得）




Link Layer: 6-57

2025中科大网络

路由到其他子网：寻址

- R决定数据报的传出接口，将源IP地址为A，目标IP地址为B的数据报交链路层
- R创建链路层的帧包含A-B IP数据报，帧的目标地址：B的MAC地址
- 传输链路层的帧




Link Layer: 6-58

2025中科大网络

路由到其他子网：寻址

- B接收到该帧，解封装IP数据报，目标为B
- B将数据报向上传递到IP协议实体




Link Layer: 6-59

2025中科大网络

链路层，LAN：提纲

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络




- Web请求的历程

Link Layer: 6-60

Ethernet

“占主导地位”有线LAN技术:

- 第一个被广泛使用的LAN技术
- 更简单, 便宜
- 跟上速度竞赛: 10 Mbps – 400 Gbps
- 单芯片, 多速率 (例如: 博通Broadcom BCM5761)




Metcalfe's Ethernet sketch

<https://www.uspto.gov/learning-and-resources/journeys-innovation/audio-stories/defying-doubters>


Link Layer: 6-61

以太网: 物理拓扑


- **总线型**: 上世纪90年代流行的拓扑
 - 所有的节点在一个碰撞域内 (可能相互碰撞, 同时只能有一个节点在发送)
- **交换型**: 现在占主导地位
 - 在交换机进行主动的链路层 (2层) 交换
 - 每个 “spoke端口” 单独运行以太网协议 (节点间不会相互发生碰撞)



总线: 同轴电缆



集线器: 盒中总线



交换机: 交换型以太网网络

Link Layer: 6-62

Ethernet帧结构

发送接口将IP数据报 (或者其他网络层协议包) 封装在以太网帧中




前导码:

- 用于同步接收方、发送之间的时钟速率
- 7个字节的10101010, 后面紧跟着1个字节的10101011

Link Layer: 6-63

Ethernet帧结构 (续)



- **地址**: 6字节目标MAC地址, 6字节源MAC地址
 - 如果适配器收到一个目标地址是本节点MAC地址, 或者是广播地址的帧 (如: ARP请求报文), 它将帧的数据部分向上交给网络层
 - 否则, 适配器丢弃该帧
- **类型/长度**: 指示高层的协议 (1536以下代表长度, 以上代表类型)
 - 绝大多数为IP, 但是可能有其他协议, 如: Novell IPX, AppleTalk
 - 在接收方进行多路解复用
- **CRC**: 在接收方进行CRC校验
 - 检测到差错: 帧被丢弃

Link Layer: 6-64


Ethernet: 不可靠，无连接

- **无连接**: 发送方在发送帧前和接收方NIC无需握手
- **不可靠**: 接收方NIC无需发送ACK或NAK给发送方NIC
 - 如果帧出错被丢弃，发送方NIC不会恢复
 - 源主机的IP层也不会恢复
 - 如源主机采用传输层协议是TCP，那么TCP会恢复丢失的帧中TCP段内容
 - 如源主机采用传输层协议是UDP，那么应用层会看到应用数据的部分丢失
- Ethernet的MAC协议: 具有二进制指数退避的非时隙CSMA/CD

Link Layer: 6-65

802.3 Ethernet 标准: 链路层和物理层

- 很多以太网标准
 - 一致的MAC协议和帧结构
 - 不同的速率: 2 Mbps, 10 Mbps, 100 Mbps, 1Gbps, 10 Gbps, 40 Gbps, 100Gbps, 400Gbps, 800Gbps
 - 不同的物理层介质: 光纤，双绞线



Link Layer: 6-66

链路层，LAN: 提纲

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - **交换机**
 - VLANs
- 链路虚拟化: MPLS
- 数据中心网络



- Web请求的历程

Link Layer: 6-67

Ethernet 交换机


- **链路层**设备: 扮演一个**主动**角色，存储、转发以太网帧
 - 检查帧的目标MAC地址，转到该MAC地址对应的交换机端口
 - 如果是广播帧，向交换机所有端口转发
 - 如果端口设置的是点到点专用模式，全双工、无冲突，则直接发送
 - 如果下挂HUB或设置成半双工模式，转发前采用CSMA/CD获得该网段的访问权
- **透明**: 主机（和路由器）的IP层次不知道交换机的存在
- **即插即用，自学习**
 - 学习MAC地址和交换机端口的映射关系，使用交换表转发帧
 - 交换机无需配置就可以工作

Link Layer: 6-68

交换机: 多个同时的传输

2025中科大网络

- 主机--交换机端口: 专有、直接连接
- 交换机缓存帧、转发帧
- 在每个输入链路上使用以太网协议, 所以:
 - 无冲突、全双工
 - 每条链路都本身就是一个碰撞域
- 交换:** A-to-A' 和 B-to-B' 可以同时传输, 没有碰撞




Link Layer: 6-69

交换机: 多个同时的传输

2025中科大网络

- 主机--交换机端口: 专有、直接连接
- 交换机缓存帧、转发
- 在每个输入链路上使用以太网协议, 所以:
 - 无冲突、全双工
 - 每条链路都本身就是一个碰撞域
- 交换:** A-to-A' 和 B-to-B' 可以同时传输, 没有碰撞
 - 但是A-to-A' 和 C to A' 的传输不能同时进行



Link Layer: 6-70

交换机转发表

2025中科大网络


Q: 交换机如何知道A'可以通过接口4可达, 而B'可以通过接口5可达?

A: 每个交换机有一个**交换表**, 每个表项:

- (主机的MAC地址, 到达该主机的接口, 时戳)
- 看起来就像路由器表!

Q: 表项是如何在交换表中被创建与维护的?

- 类似于路由协议?




Link Layer: 6-71

交换机: 自学习

2025中科大网络

- 交换机**学习**可以通过哪个交换机端口到达哪些MAC

- 当帧被接收时, 交换机“学习”发送方的位置: 进入LAN的网段, 即交换机端口
- 在交换表中记录(发送方MAC/位置交换机端口)对



MAC addr	interface	TTL
A	1	60

Switch table (initially empty)

Link Layer: 6-72

交换机: 帧过滤/转发


当交换机接收到帧时:

1. 记录进入的链路 (交换机端口, 发送主机的MAC地址)
2. 用帧的目标MAC地址检索交换表
3. **if** 该目标MAC地址在交换表中的表项中能够被发现
 then {
 if 目标MAC地址在进入该帧的网段 (交换机端口)
 then 丢弃该帧
 else 向交换表表项指示的接口转发该帧
 }
 else 泛洪 /* 除了帧进入的端口, 向所有其他端口转发 */

Link Layer: 6-73

自学习, 转发: 例子

- 帧的目标 A', 如位置不知道: **泛洪**
- 如目标 A' 位置知道
 就向一个链路 (端口) 选择性发送




MAC addr	interface	TTL
A	1	60
A'	4	60

交换表
(初始为空)

Link Layer: 6-74

交换机互联

自学习交换机可以级联到一起:




Q: 从A发送到G - S₁交换机如何知道需要通过S₄和S₃转发目标为G的帧?

- **A:** 自学习! (工作原理和单个交换机是完全一样的)

Link Layer: 6-75

自学习多个交换机的例子

假设C发送帧到I, I回应给C




Q: 显示交换机表和数据帧在S₁, S₂, S₃, S₄中的转发

Link Layer: 6-76

小型机构网络

2025中科大网络



Link Layer: 6-77

交换机 vs. 路由器


2025中科大网络

都是存储转发设备:

- **路由器**: 网络层设备(检查网络层头部)
- **交换机**: 链路层设备(检查链路层头部)

都有转发表:

- **路由器**: 采用路由选择算法计算路由表, 基于IP地址
- **交换机**: 采用泛洪、自学习来获得转发表(站表), 基于MAC地址




Link Layer: 6-78

链路层, LAN: 提纲

2025中科大网络

- 引论
- 检错, 纠错
- 多路访问协议
- **LANs**
 - 编址, ARP
 - 以太网
 - 交换机
 - **VLANs**
- 链路虚拟化: MPLS
- 数据中心网络




- Web请求的历程

Link Layer: 6-79

Virtual LANs (VLANs): 动机

2025中科大网络

Q: 当LAN的规模不断增大, 用户不断变换其上网地点会发生什么?



多个**碰撞域** (冲突域)

- 采用多个(级)交换机进行数据帧的交换
- 交换机的每个端口都是一个碰撞域, 可以同时允许多个站点发送


但是所有处在一个**广播域**:

- **扩展性**: 所有的2层广播流量 (ARP, DHCP, 目标MAC未知的帧) 必须穿过整个LAN
- 效率, 安全性, 隐私性问题

Link Layer: 6-80

Virtual LANs (VLANs): 动机

Q: 当LAN的规模扩大，用户变换接入网络的连接点时，什么会发生？



1个广播域:

- **扩展性:** 所有2层的广播流量（ARP, DHCP, 未知的MAC）必须穿过整个LAN
- 效率，安全，隐私性问题

管理问题:

- CS用户将其办公室移动到EE-物理上接入EE交换机
- 但仍然希望逻辑地通过CS交换机接入，CS的广播流量被限制在CS交换机范围内


Link Layer: 6-81

基于端口的 VLANs


Virtual Local Area Network (VLAN)

在单个物理LAN基础设施（交换机构成的网络）上，支持VLAN能力的交换机可以被配置成定义多个**虚拟VLAN**

基于端口的VLAN: 交换机端口分组（通过交换机管理软件），以便于**单个**物理交换机.....




.. 作为多个虚拟交换机运行



Link Layer: 6-82


基于端口的 VLANs

- **流量隔离:** 进出1-8端口的帧可以只到达端口1-8，广播帧的范围可控，解决可扩展问题
 - 不仅可以基于端口的定义VLAN
 - 也可以基于节点MAC地址定义VLAN
- **动态成员:** 可以在VLAN中动态分配端口，可管理问题
- **在VLAN之间转发:** 通过路由进行（就像使用单独交换机一样）
 - 实际上设备商供应：集成了交换机和路由器的设备-三层交换
 - 一次路由，多次交换



Link Layer: 6-83

跨越多个交换机的VLAN




干线端口: 在多个交换机之间共享所定义的VLAN

- 通过干线端口（而不是接入端口），干线转发交换机之间的帧
- 在干线上，交换机间转发的帧不是普通802.1的帧（必须携带VLAN ID信息）
- 802.1q协议规范了：在干线端口转发的帧，如何增加和删除额外的头部字段

Link Layer: 6-84

802.1Q VLAN 帧格式



Link Layer: 6-85

链路层，LAN：提纲

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络




- Web请求的历程

Link Layer: 6-86

多协议标签交换 (MPLS: Multiprotocol label switching)

- 目标：采用固定长度的标签，在具有MPLS能力的路由器间进行快速的IP转发 (替代目标IP地址的最长前缀匹配)
 - 采用固定长度标签标识进行更加快速的查找
 - 借鉴了虚电路方法的思路
 - 但是IP数据报仍然保留IP地址！




Link Layer: 6-87

具有MPLS能力的路由器

- a.k.a. 标签交换路由器
- 仅基于标签值将数据报转发到输出链路 (不再检查数据报的IP地址)
 - MPLS转发表和IP转发表不同
- 弹性：MPLS转发确定可能与IP不同
 - 采用目标和源地址将到同样目标的流区分处理 (流量工程)
 - 如果链路失效可以机型快速重新路由：预先计算的备份路径

Link Layer: 6-88


MPLS versus IP 路径



- **IP 路由**: 到达目标的路径仅由目标地址决定

Link Layer: 6-89

MPLS versus IP 路径




- **IP 路由**: 到达目标的路径仅由目标地址决定
- **MPLS 路由**: 到达目标的路径可以基于源和目标地址
 - 通用转发的风格 (MPLS 10年前)
 - **快速重新路由**: 当发生链路失效时采用预先计算的备份路由

Link Layer: 6-90


MPLS 信令

- 修改OSPF, IS-IS链路状态泛洪协议让它们用于携带MPLS路由所需要信息:
 - e.g., 链路带宽, “预留”链路带宽的量
- MPLS入口路由器采用RSVP-TE信令协议来在下游路由器上设置MPLS转发



Link Layer: 6-91

MPLS 转发表



Link Layer: 6-92

链路层，LAN：提纲

2025中科大网络

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- **数据中心网络**



- Web请求的历程

Link Layer: 6-93

数据中心网络

2025中科大网络

1w到10w台主机，紧耦合，物理位置相近：

- 电子商务 (e.g. Amazon)
- 内容服务器 (e.g., YouTube, Akamai, Apple, Microsoft)
- 搜索引擎，数据挖掘 (e.g., Google)

挑战：

- 多种应用，每种服务有大量的客户
- 可靠性要求高
- 管理/负载均衡，避免处理，网络里，数据瓶颈




Inside a 40-ft Microsoft container, Chicago data center

Link Layer: 6-94

数据中心网络：网元

2025中科大网络



边界路由器

- 连接到数据中心外部

Tier-1 交换机

- 下面连接到大约 ~16 T-2 交换机

Tier-2 交换机

- 下面连接到大约 ~16 TORs

机顶 (TOR) 交换机

- 每个机柜一个
- 40-100Gbps 以太网到刀片

服务器阵列


- 20-40 服务器刀片：主机

Link Layer: 6-95

数据中心网络：网元

2025中科大网络

Facebook F16 数据中心网络拓扑：




<https://engineering.fb.com/data-center-engineering/f16-minipack/> (posted 3/2019)

Link Layer: 6-96

数据中心网络：多路径

2025中科大网络

- 交换机，阵列之间的丰富互联：
 - 增加阵列之间吞吐（可能有多路由路径）
 - 通过冗余增加可靠性




在阵列1和11之间的2个突出显示的不交叉路径

Link Layer: 6-97

数据中心网络：应用层路由

2025中科大网络



负载均衡：应用层路由

- 接收外部的客户端请求
- 导流工作载荷到数据中心
- 向外部的客户端返回结果
- (对客户隐藏了数据中心的内部结构等细节)

Link Layer: 6-98

数据中心网络：协议创新

2025中科大网络


- 链路层：
 - RoCE: remote DMA (RDMA) over Converged Ethernet
- 传输层：
 - ECN (explicit congestion notification) 被用于传输层的拥塞控制 (DCTCP, DCQCN)
 - 逐跳（反向压力）拥塞控制实验
- 路由，管理：
 - 在机构的数据中心内部和之间SDN 被广泛使用
 - 将相关服务和数据尽可能放置近一些，（例如：在一个阵列或者相近的阵列中）最小化2级，1级的通信

Link Layer: 6-99

链路层，LAN：提纲

2025中科大网络

- 引论
- 检错，纠错
- 多路访问协议
- LANs
 - 编址，ARP
 - 以太网
 - 交换机
 - VLANs
- 链路虚拟化：MPLS
- 数据中心网络



Web请求的历程

Link Layer: 6-100

综合：web页面请求的历程


2025中科大网络

- 我们自上而下的协议栈旅行结束了！
 - 应用层，传输层，网络层和链路层
- 把它们放到一起按照时间线展开介绍各协议实体动作！
 - **目标：**识别、复习、理解看似简单的场景中所涉及的协议（所有层次）：请求www页面
 - **场景：**学生将笔记本连接到校园网，请求和接收www.google.com的网页

Link Layer: 6-101

历程：场景

2025中科大网络



场景:


- 到达的移动客户端连接到了网络 ...
- 请求web网页：www.google.com

看起来很简单!

Link Layer: 6-102

历程：连接到互联网

2025中科大网络




- 连接的笔记本需要一个IP地址，第一跳路由器的IP地址，DNS的地址: 采用DHCP
- ❖ DHCP 请求被封装在UDP中，封装在IP数据报中，封装在802.3以太网帧中
- ❖ 以太网的帧在LAN上广播 (dest: FFFFFFFFFF), 被运行中的DHCP服务器接收到
- ❖ 以太网帧中封装IP分组，封装UDP，UDP数据报封装DHCP请求报文

Link Layer: 6-103

历程：连接到互联网

2025中科大网络




- DHCP 服务器生成DHCP ACK 包括客户端IP地址，第一跳路由器IP地址和DNS名字服务器地址
- 在DHCP服务器进行封装，帧通过LAN转发（交换机学习），在客户端进行解封装
- DHCP 客户端接收 DHCP ACK 响应报文

客户端现在拥有IP地址，知道DNS服务器的名字和地址，以及第一跳路由器的IP地址

Link Layer: 6-104

历程... ARP (在DNS和HTTP之前)

2025中科大网络




- DNS 在发送HTTP请求报文之前，需要 www.google.com 的IP地址
- DNS查询报文被创建，封装在UDP数据报中，封装在IP数据报中，封装在以太网帧中，将之发送给路由器，需要路由器接口的MAC地址：ARP
- ARP查询广播发送，路由器接收，然后路由器给出ARP响应报文，告诉请求方路由器接口的MAC地址
- 客户端现在知道第一跳路由器的MAC地址，所以它可以发送包含有DNS查询的帧了

Link Layer: 6-105

历程... 使用DNS

2025中科大网络




- IP数据报（包含DNS请求报文）解封装给DNS
- DNS服务器用 www.google.com 的IP地址来回复给客户端
- 包含有DNS查询的IP数据报通过LAN交换机从客户端转发到第一跳路由器
- IP数据报从校园网转发到Comcast网络，路由（表项被RIP, OSPF, IS-IS和/或BGP路由协议）到DNS服务器

Link Layer: 6-106

历程...承载有HTTP的TCP连接

2025中科大网络




- 为了发送HTTP请求，客户端首先打开到web服务器的TCP socket
- TCP SYN 段 (TCP 3次握手的第一步) 通过域间路由到web服务器
- Web服务器用TCP SYNACK (TCP 连接的第2步) 响应客户端
- TCP 连接建立起来!

Link Layer: 6-107

历程... HTTP 请求/响应

2025中科大网络



- HTTP 请求发送给TCP socket
- 包含有HTTP请求的IP数据报路由到www.google.com
- web 服务器用HTTP 响应报文（包含有web网页）回应
- 包含有HTTP 响应报文的IP数据报路由回客户端

Link Layer: 6-108

第6章：总结

- 数据链路层服务背后的原理：
 - 检错，纠错
 - 共享广播型信道：多路访问
 - 链路层编址
- 各种链路层技术的实例和实现
 - 以太网
 - 交换式局域网，VLANs
 - 虚拟化成链路层的网络：MPLS
- 综合：web请求的历程

Link Layer: 6-109

第6章：让我们休息一下

- 自顶向下讲解全部网络协议栈旅程结束了（除了物理层）
- 坚实理解了网络原理和实践！
- ……可以在这里停下…。但是有更加有趣的主题！
 - 无线网络
 - 网络安全

Link Layer: 6-110

第6章 附加幻灯片

Network Layer: 5-111

纯 ALOHA 效率

$$\begin{aligned}
 P(\text{给定节点成功}) &= P(\text{该节点传输}) * \\
 &\quad P(\text{没有其他节点在 } [t_0-1, t_0] \text{ 传输}) * \\
 &\quad P(\text{没有其他节点在 } [t_0, t_0+1] \text{ 传输}) * \\
 &= p \cdot (1-p)^{N-1} \cdot (1-p)^{N-1} \\
 &= p \cdot (1-p)^{2(N-1)}
 \end{aligned}$$

... 选择最优点p, 让 $n \rightarrow \infty$

$$= 1/(2e) = .18$$

甚至比时隙Aloha要来得差!

Link Layer: 6-112