



中山大学 软件工程学院

SUN YAT-SEN UNIVERSITY SCHOOL OF SOFTWARE ENGINEERING

SSE206 《计算机网络》

第四章 网络层：数据平面

南雨宏

nanyh@mail.sysu.edu.cn

2026-04-20

提纲

- 第 1 章 计算机网络和因特网
- 第 2 章 应用层
- 第 3 章 传输层
- 第 4 章 网络层：数据平面
- 第 5 章 网络层：控制平面
- 第 6 章 链路层与局域网
- 第 7 章 无线网络和移动网络
- 第 8 章 计算机网络中的安全

第 4 章：网络层：数据平面

4.1 网络层概述

- 数据平面
- 控制平面

4.2 路由器工作原理

4.3 网际协议 IP

- 数据报格式
- 分片
- IPv4地址
- NAT：网络地址转换
- IPv6

4.4 通用转发和SDN

- 匹配
- 行动
- OpenFlow有关 “匹配+行动” 的运行实例

4.5 中间盒


第 4 章：网络层：数据平面

本章目标:

- 理解网络服务的基本原理，聚焦于其数据平面
 - 网络服务模型
 - 转发和路由
 - 路由器工作原理
 - 通用转发
- 互联网中网络层协议的实例和实现

网络层服务和协议

- 在发送主机和接收主机对之间传送段 (segment)
 - 发送端：将段封装到数据报中
 - 接收端：将段上交给传输层实体
- 网络层协议存在于**每一个**主机和路由器
- 路由器：
 - 检查每一个经过它的IP数据报的头部
 - 将数据报从输入端口移动到输出端口，以沿端到端路径传输数据报



网络层的关键功能

网络层功能

- **转发**：将分组从路由器的输入接口转发到合适 的输出接口
- **路由选择**：使用路由算法来 决定分组从**发送主机**到**目标接收主机**的路径
 - 路由选择协议
 - 路由选择算法

旅行的类比：

- **转发**：通过单个路口的过程
- **路由选择**：从源到目的的路径规划过程



forwarding



routing

网络层:数据平面、控制平面

数据平面 Data plane:


- 本地的、每个路由器的功能
- 决定从某个端口进入的分组从哪个端口输出
- 转发功能
 - 传统方式：基于目标地址 + 转发表（路由表）
 - SDN 方式：基于多个字段+流表

控制平面 Control plane:


- 网络范围内的逻辑
- 决定数据报如何沿着从源主机到目标主机的端到端路径，在路由器之间路由
- 2种控制平面方法：
 - 传统路由算法：在单个路由器上实现
 - Software-defined networking (SDN): 在远程服务器实现

传统方式：单个路由器(Per-router)控制平面

在每一个路由器中的单独路由器算法元件，在控制平面进行交互。




传统方式：路由和转发的相互作用



SDN 方式：逻辑集中的控制平面

一个不同的（通常是远程的）控制器与本地控制代理（CAs）交互。



网络服务模型

Q: 作为从发送方主机到接收方主机传输数据报的“通道”，网络提供什么样的服务模型？

对于单个数据报的服务：

- 可靠传送
- 延迟保证
 - 例如：延迟少于40ms

对于数据报流的服务：

- 保序数据报传送
- 保证流的最小带宽
- 分组之间的延迟差

连接建立

- 分组传输之前，两个主机之间，在通过**一些路由器**所构成的路径上建立一个网络层连接
- 网络层和传输层连接服务区别：
 - **传输层**: 在2个进程（端口）之间，很可能只体现在端系统上（TCP连接）
 - **网络层**: 在2个主机之间，涉及到路径上的一**系列路由器**

网络层服务模型

网络架构	服务模型	服务质量 (Quality of Service, QoS) 保证 ?				拥塞反馈
		带宽	丢失	保序	延迟	
Internet	best effort	none	no	no	no	no (inferred via loss)
ATM	CBR 恒定速率	constant rate	yes	yes	yes	no congestion
ATM	VBR 变化速率	guaranteed rate	yes	yes	yes	no congestion
ATM	ABR 可用比特率	guaranteed Minimum	no	yes	no	yes
ATM	UBR 不指名比特率	none	no	yes	no	no

网络层服务模型

网络架构	服务模型	服务质量 (Quality of Service, QoS) 保证 ?				拥塞反馈
		带宽	丢失	保序	延迟	
Internet	best effort	none	no	no	no	no (inferred via loss)

互联网 “尽最大努力” 服务模式

不保证:

- i. 成功将数据报传递到目的地
- ii. 交货的时间或顺序
- iii. 端到端可用的带宽

关于尽最大努力服务的思考

- 简单的机制使互联网得以广泛部署
- 采用充足的带宽供应使实时应用程序（如交互式语音、视频）的性能在“大部分时间”内“足够好”
- “弹性”服务的拥塞控制有助于.....（如防止网络崩溃、尽可能利用网络资源、同时保障基本传输服务）

尽最大努力服务模式的成功是毋庸置疑的

第 4 章：网络层：数据平面

4.1 网络层概述

- 数据平面
- 控制平面

4.2 路由器工作原理

4.3 网际协议 IP

- 数据报格式
- 分片
- IPv4地址
- NAT：网络地址转换
- IPv6

4.4 通用转发和SDN

- 匹配
- 行动
- OpenFlow有关 “匹配+行动” 的运行实例

4.5 中间盒


路由器工作原理

- 在4.2节中，将深入探讨路由器的内部硬件操作
 - 输入和输出分组处理
 - 路由器的内部交换机制
 - 分组排队和调度

路由器结构概况


高层抽象 (简化)的通用路由器体系架构:

- 路由: 运行路由选择算法/协议 (RIP, OSPF, BGP)-生成路由表
- 转发: 从输入到输出链路交换数据报-根据路由表进行分组的转发




路由器结构概况

通用路由器架构类比图:



输入端口功能



物理层:
Bit级的接收


以毫秒为单位进行操作

分布式交换:

- 根据数据报头部的信息（如目的地址），在输入端口内存中的转发表中查找合适的输出端口（匹配+行动）
- 目标：以“线速”完成输入端口处理
 - 处理速度与物理链路的传输速率保持同步
- 如果数据报到达交换机的速度比转发速度快，则会在**输入端口排队**

数据链路层:
链路层协议动作、解封装
e.g., Ethernet
见第六章

输入端口功能



物理层:
Bit级的接收

数据链路层:
链路层协议动作、解封装
e.g., Ethernet
见第六章

以毫秒为单位进行操作

分布式交换:

- 基于目标的转发: 仅仅依赖于IP数据报的目标IP地址 (传统方法)
- 通用转发: 基于头部字段的任意集合进行转发

基于目标的转发

<i>forwarding table</i>	
Destination Address Range	Link Interface
11001000 00010111 00010000 00000000 through 11001000 00010111 00010000 00000100	0
11001000 00010111 00010000 00000111	
11001000 00010111 00011000 11111111	
11001000 00010111 00011001 00000000 through 11001000 00010111 00011111 11111111	2
otherwise	3

Q: 如果地址范围没有划分的特别规整，会发生什么？

最长前缀匹配

longest prefix match

当给定目标地址查找转发表时，采用**最长**地址前缀匹配的目标地址表项。

Destination Address Range	Link interface
11001000 00010111 00010 *** *****	0
11001000 00010111 00011000 *****	1
11001000 00010111 00011 *** *****	2
otherwise	3

examples:

11001000 00010111 **00010**110 10100001

which interface?

11001000 00010111 **00011000** **10101010**

which interface?

最长前缀匹配

longest prefix match

当给定目标地址查找转发表时，采用**最长**地址前缀匹配的目标地址表项。

Destination Address Range	Link interface
11001000 00010111 00010 *** *****	0
11001000 00010111 00011000 *****	1
11001000 (match! 00011 *** *****	2
otherwise	3

examples:

11001000 00010111 00010110 10100001
11001000 00010111 00011000 10101010

which interface?

which interface?

最长前缀匹配

longest prefix match

当给定目标地址查找转发表时，采用**最长**地址前缀匹配的目标地址表项。

Destination Address Range	Link interface
11001000 00010111 00010 *** *****	0
11001000 00010111 00011000 *****	1
11001000 00010111 00011 *** *****	2
otherwise	3

match!

examples:

11001000 00010111 00010110 10100001

which interface?

11001000 00010111 00011000 10101010

which interface?

最长前缀匹配

longest prefix match

当给定目标地址查找转发表时，采用**最长**地址前缀匹配的目标地址表项。

Destination Address Range	Link interface
11001000 00010111 00010 *** *****	0
11001000 00010111 00011000 *****	1
11001000 00010111 00011 *** *****	2
otherwise	3

match!

examples:

11001000 00010111 00010110 10100001

11001000 00010111 00011000 10101010

which interface?


which interface?

最长前缀匹配（了解）

- 我们将会在学习IP地址时，简单讲解为什么采用最长前缀匹配
- 最长前缀匹配：在路由器中经常采用三态内容可寻址存储器（Tenary Conten Address Memory, TCAM）来完成
 - 内容可寻址：将地址交给 TCAM，它可以不管表空间有多大，在一个时钟周期内检索出地址
 - Cisco Catalyst 系列路由器：在 TCAM 中可以存储多达约为 1百万条路由表项




交换结构 (Switching fabrics)

- 将分组从输入缓冲区传输到合适的输出端口
- **交换速率**：分组可以按照该速率从输入传输到输出
 - 运行速度经常是输入/输出链路速率的若干倍
 - N 个输入端口：交换结构的交换速度是输入线路速度的N倍比较理想，才不会成为瓶颈



交换结构


- 将分组从输入缓冲区传输到合适的输出端口
- **交换速率**：分组可以按照该速率从输入传输到输出
 - 运行速度经常是输入/输出链路速率的若干倍
 - N 个输入端口：交换结构的交换速度是输入线路速度的N倍比较理想，才不会成为瓶颈
- 三种典型交换结构



通过内存 (memory) 交换


第一代路由器:

- 在 CPU 直接控制下的交换, 采用传统的计算机
- 分组被拷贝到系统内存, CPU从分组的头部提取出目标地址, 查找转发表, 找到对应的输出端口, 拷贝到输出端口
- 转发速率被内存的带宽限制 (数据报通过 BUS 两遍)
- 一次只能转发一个分组





通过总线 (bus) 交换

- 数据报通过共享总线，从输入端口转发到输出端口
- **总线竞争**: 交换速度受限于总线带宽
- 一次处理一个分组
- 对于接入或企业级路由器，速度足够（但不适合区域或骨干网络）
 - 1 Gbps bus - Cisco 1900; 32 Gbps bus - Cisco 5600



通过互联网络（crossbar 等）交换

- 同时并行转发多个分组，克服总线带宽的限制
- Banyan（榕树）网络，crossbar (纵横) 和其它的互联网络被开发，连接多处理器
- 多级交换机： $n \times n$ 由多级较小交换机组成的交换机
 - 当分组从端口A到达，转给端口Y；控制器短接相应的两个总线
- 并行性的高级设计
 - 在输入时，将数据报分片为固定长度的信元，
 - 通过交换网络交换，在出口重新组装数据报




通过互联网络交换

- 伸缩，同时使用多个切换“平面”：

- 通过并行加速、放大


- Cisco CRS 路由器：

- 基本单元：8个交换平面
- 每个平面有一个三级交换网络
- 高达 100 Tbps 的交换容量




输入端口缓存

- 当交换结构的速率小于输入端口的汇聚速率时，在输入端口可能要排队
 - 排队延迟以及由于输入缓存溢出造成丢失!
- **Head-of-the-Line (HOL) blocking**: 排在队头的数据报阻止了队列中其他数据报向前移动（绿色分组被阻塞）




输出端口竞争（红色分组）：
只能有一个红色分组被传递，交换到一个
输出端口，下面红色的分组被阻塞



一个分组时间（绿色分组）：
绿色分组经历了头端阻塞

输出端口排队




- 当数据报从交换结构的到达速度比链路传输速率快，就需要输出端口缓存
 - 删除策略：如果没有空闲缓冲区，要删除哪个数据报？
- 由调度规则选择排队的数据报进行传输


数据报（分组）可能会因为拥塞、缓冲区没有空间，而被丢弃

优先级调度 - 谁会获得最佳性能，网络中立？

输出端口排队



at t , packets more
from input to output



one packet time later


- 假设交换速率 R_{switch} 是输出链路 R_{line} 的 N 倍 (N : 输入端口的数量)
 - 当多个输入端口同时向输出端口发送时, 缓存该分组 (当通过交换网络到达的速率超过输出速率则缓存)
 - 调度问题: 排队带来延迟, 由于输出端口缓存溢出则丢弃数据报!

需要多少缓存?


- 更大的缓冲区:
 - 能够承受分组到达速率更大的波动, 从而降低分组丢失率
 - 更长的排队时延
- RFC 3439 拇指规则 (经验性规则) : 平均缓存大小 = 典型的RTT (例如: 250ms) 倍于链路容量 C
 - e.g., $C = 10 \text{ Gbps link}$
 - $250\text{ms} * 10\text{Gbps} = 2.5 \text{ Gbit buffer}$
- 最近的一些推荐: 有 N (非常大) 个流, 缓存大小等于

$$\frac{\text{RTT} \cdot C}{\sqrt{N}}$$

分组调度 (Buffer Management)



Abstraction: queue




调度机制:

- **丢弃策略:** 如果分组到达一个满的队列, 哪个分组将会被抛弃?
 - **tail drop:** 丢弃刚到达的分组
 - **priority:** 根据优先权丢失/移除分组
 - **random:** 随机地丢弃/移除
- 同时对分组做标记: 表明网络拥塞程度 (ECN, RED)
 - 将哪些分组进行标记?

数据包调度

- **调度**：决定下一个在链路上发送哪个数据包
 - 先到先得 first come, first served
 - 优先权 Priority
 - 轮循 round robin
 - 加权公平排队 weighted fair queueing

Abstraction: queue



数据包调度： FCFS （先进先出 FIFO）


- **调度：** 决定下一个在链路上发送哪个数据包

- 先到先得 first come, first served
- 优先权 Priority
- 轮循 round robin
- 加权公平排队 weighted fair queueing

- **FCFS/FIFO：** 按到达顺序发送到输出端口的数据包

- 也称为先进先出 (FIFO)
- 真实世界的例子？



Abstraction: queue




调度策略：优先权

优先权调度 (Priority scheduling) :

- 发送最高优先权的分组
- 到达的流量分类，不同类别有不同的优先权：
 - 类别可能依赖于标记或者其他的头部字段, e.g. IP source/dest, port numbers, ds, etc
 - 先传高优先级的队列中的分组，除非没有
 - 高（低）优先权中的分组传输次序：FIFO




调度策略： 循环 (Round Robin)



RR (Round Robin scheduling) 调度:

- 到达的流量分类，按类别排队
 - 任何报头字段都可以用于分类
 - 例1：IP首部中的服务类型字段 (ToS/DSCP)
 - 例2：源IP地址或目的IP地址
- 循环扫描不同类型的队列, 发送完一类的一个分组，再发送下一个类的一个分组，循环所有类



调度策略：加权公平排队

Weighted Fair Queuing (WFQ) 加权公平排队：

- 一般化的 Round Robin
- 每个类 i 都有权重 w_i ，并在每个循环中得到加权的 service 量
 - 在一段时间内，每个队列得到的 service 时间是：

$$\frac{w_i}{\sum_j w_j}$$

- 最低带宽保证(每个流量等级)

